



热力学与统计物理

一团纷乱无序的碎碎念

作者: Fisher The First

组织: 鸢

时间: April 4, 2024

版本: 笔记初稿

邮箱: samjiajun@outlook.com

在没有结束前，总要做很多没有意义的事，这样才可以在未来某一天，用这些无意义的事去堵住
那些讨厌的缺口

第 1 章 概率与无规行走

♥我记得她很容易害羞,记得她容易脸红的事,记得她在信纸下为我写的每个字,却再也没有见过她。一次我把信很容易哭了出来,记得她容易脸红的事,记得她在信纸下为我写的每个字,却再也没有见过她。♥

1.1 无规行走与二项分布

在进入统计物理前,对分布与概率进行讨论是大有裨益的。我们暂且不论概率的具体数学,并假设在阴郁的夜晚我酩酊大醉的站在实轴的原点 $x = 0$ 处,这里有一个路灯。从此处,我胡乱的走,没有一步是具有主观意识的,因而从统计上看我们可以每一步假定向正方向走的概率为 p ,而反向之概率为 q 。如果有人为我心忧,她自然会想,我究竟会去向何方,并敏锐的给出如下问题。我们假定每步的步长均为 1 个单位。

恒定步长无规行走

假设他稀里糊涂的走了 N 步,我们探求他 N 步后的位置 x

1. N 步后他位于 $x = m$ 的概率
2. N 步后,他的位置 x 均值与方差。
3. 若 N 非常之大又如何呢

问题 1

不难看出, x 是一个离散型变量,且符合二项分布。设右方为正方向,我们假定他一共向右走了 n_l 步,向左走了 n_r 步, n_l 与 n_r 符合二项分布。设出 n_l, n_r 两个变量并不代表它们相互独立,但我们将看见这种标识下概率具有对称性。

恒步长无规行走概率

向左向右分别以 n_l, n_r 标识那么

$$P(n_r = n_1) = P(n_l = n_2) = \frac{N!}{n_1!n_2!} p^{n_1} q^{n_2} \quad (1.1)$$

$$P(x = m) = P(n_r = \frac{N+m}{2}) = P(n_l = \frac{N-m}{2}) = \frac{N!}{(\frac{N+m}{2})!(\frac{N-m}{2})!} p^{(\frac{N+m}{2})} q^{(\frac{N-m}{2})} \quad (1.2)$$

问题 2

我们已熟知二项分布的均值与方差，但其中有一个有趣的偏导的小技巧

性质 一个小技巧

$$\overline{n_r} = \sum_{n_i=0}^{n_i=N} n_i P(n_i) = \sum_{n_i=0}^{n_i=N} n_i C_N^{n_i} p^{n_i} q^{N-n_i} = p \frac{\partial}{\partial p} \sum_{n_i=0}^{n_i=N} C_N^{n_i} p^{n_i} q^{N-n_i} = p \frac{\partial}{\partial p} (p+q)^N = Np$$

由此，我们可得

恒步长无规行走均值与方差

1. $\overline{n_r} = Np, \quad \overline{n_l} = Nq, \quad (\overline{\Delta n_r})^2 = (\overline{\Delta n_l})^2 = Npq$
2. $\overline{m} = \overline{n_1 - n_2} = N(p - q)$
3. $(\overline{\Delta m}) = (2n_l - N) - \overline{2n_l - N} = 2\Delta n_l$
4. $(\overline{\Delta m})^2 = 4Npq$

问题 3

第三个问题颇有难度，当 N 非常大时我们有预见处理对象 x 不再为离散型，而转为连续型变量。我们称这个变量准连续。我们暂不论这种转变的细节，而直接给出

定理 1.1 (准连续定理)

当 $P(n_l + 1) - P(n_l) \ll P(n_l)$ 时，可将 $P(n_l)$ 视为准连续函数



她或许会敏锐得察觉到，对于值不能大于 1 的概率函数，何有远大于之说呢？实际上，在峰值附近准连续条件总是符合得相当好的，即使 N 并非想象中那么大。我们将 $w(n)$ 在峰值处展开，我们将看到，高斯函数将是一个相当好的近似。

在准连续近似下，我们讨论对象变为了概率密度 $w(n_l), w(n_r)$ 。

定理 1.2 (高斯分布近似)

$$w(n) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(n-\mu)^2}{2\sigma^2}}$$

其中 $\mu = \overline{n}, \quad \sigma^2 = (\overline{\Delta n})^2$



令人愉快的是，确定 N 相当大时的分布（高斯分布），我们只需要计算均值方差（而且已经在问题 2 中得到了解决），而不需要每次都通过下面的并非愉快的证明。

证明 $\frac{dw}{dn}|_{n_0} = 0 \Rightarrow \frac{d(\ln w)}{dn}|_{n_0} = 0$

将 $\ln w$ 在 n_0 处展开，取到二阶项

$$\ln(w_0 + \eta) = \ln(w_0) + \eta \frac{d(\ln w)}{dn}|_{n_0} + \frac{1}{2} \eta^2 \frac{d^2(\ln w)}{dn^2}|_{n_0}$$

记 $B = \frac{1}{2} \frac{d^2(\ln w)}{dn^2}|_{n_0} < 0$ 可得

$$w = w_0 e^{-\frac{1}{2}|B|\eta^2}$$

以下计算上式中系数，我们可以通过一阶导为零，二阶导取极值，以及概率密度函数归一化条件来完成这件事情。

$$\ln w(n_1) = \text{const} + n_1 \ln p + n_2 \ln q - \ln(n_1!) - \ln(n_2!)$$

$$\text{利用准连续近似 } \frac{d \ln(n!)}{dn} = \frac{\ln n! - \ln(n-1)!}{n - (n-1)} = \ln n$$

$$\left. \frac{d \ln w(n_1)}{dn_1} \right|_{n_0} = 0 \Rightarrow \{ \ln p - \ln q - \ln n_1 - \ln(N - n_1) \} |_{n_0} = 0 \Rightarrow n_0 = Np = \bar{n}_1$$

$$\left. \frac{d^2 \ln w(n_1)}{dn_1^2} \right|_{n_0} = \left\{ -\frac{1}{n_1} - \frac{1}{N - n_1} \right\}_{\text{extreme}} = \left\{ -\frac{N}{n_1 n_2} \right\}_{\text{extreme}} = -\frac{4}{N}$$

$$\text{带入 } w = w_0 e^{-\frac{1}{2} |B| \eta^2} \text{ 得 } B = -\frac{1}{Npq}$$

最后再利用概率密度函数归一化条件可得 w_0

quod erat demonstrandum

抛开证明, 我们仍能轻易的得到当 N 相当大时, x 的概率密度函数。

恒步长无规行走概率密度函数

1. $w(n_1) = \frac{1}{\sqrt{2\pi Npq}} e^{-\frac{(n_1 - Np)^2}{2Npq}}$
2. $w(n_2) = \frac{1}{\sqrt{2\pi Npq}} e^{-\frac{(n_2 - Nq)^2}{2Npq}}$
3. $w(x) = \frac{1}{\sqrt{8\pi Npq}} e^{-\frac{(x - N(p-q))^2}{8Npq}}$

1.2 高维无规行走

她或许会进一步猜想, 我是说有这种可能, 如果我, 依旧在阴郁的夜晚酩酊大醉, 从一个位于笛卡尔平面原点的酒馆开始胡乱的走, 情况又会如何呢?

读者不难察觉这是一个 2 维问题 (当然如果我会胡乱的飞那就会有第三个维度), 而且会敏锐的发现, x, y 方向相互独立, 那么简单的概率相乘, 就能实现多维度的扩展。反之, 对于单变量的概率函数, 我们仅需对其余变量求和即可。我将此巧妙的方法叙述如下

定理 1.3 (双变量概率函数)

设双变量概率函数 $P(u, v)$ 依赖于两个的离散型变量 $u_i, v_i, (i = 1, 2 \dots N)$ 。单变量概率函数为

$$P_u(u_i) = \sum_{j=1}^N P(u_i, v_j) \quad (1.3)$$

$$P_v(v_j) = \sum_{i=1}^N P(u_i, v_j) \quad (1.4)$$

$P(u, v)$ 具有如下性质

性质

1. 归一化 $\sum_{i,j} u_i v_j P(u_i, v_j) = 1$
2. 若 u, v 统计独立, 那么 $P(u_i, v_j) = P_u(u_i) P_v(v_j)$
3. 若 u, v 统计独立 $\overline{f(u)g(v)} = \overline{f(u)} \cdot \overline{g(v)}$

对于离散变量, 仅需将求和符号改为积分号即可

定理 1.4 (双变量概率密度函数)

设双变量概率密度函数 $w(u, v)$ 依赖于两个的连续型变量 $u, v, (-\infty < u, v < +\infty)$ 。单变量概率函数为

$$w_u(u) = \int_{v=-\infty}^{+\infty} w(u, v) dv \quad (1.5)$$

$$w_v(v) = \int_{u=-\infty}^{+\infty} w(u, v) du \quad (1.6)$$

$w(u, v)$ 具有如下性质

性质

1. 归一化 $\int_{-\infty}^{+\infty} uvw(u, v)dudv = 1$
2. 若 u, v 统计独立, 那么 $w(u, v) = w_u(u)w_v(v)$
3. 若 u, v 统计独立 $\overline{f(u)g(v)} = \overline{f(u)} \cdot \overline{g(v)}$

顺便一提, 如果一个函数的自变量本身是一个连续性变量, 即**随机变量函数**

定理 1.5 (概率密度函数)

设函数 $\phi(u)$ 的自变量 u 为连续型随机变量, 记 u 的概率密度函数为 $w_u(u)$, 那么 ϕ 也将为一个连续型随机变量, 且其概率密度函数 $w_\phi(\phi)$ 为

$$w_\phi(\phi) = \{w_u(u) \left| \frac{du}{d\phi} \right| \}_\phi \quad (1.7)$$

其中因子 $\left| \frac{du}{d\phi} \right|$ 即是换元后的雅可比系数

通过严谨的定义, 我们漂亮的解决了多维无规行走问题

三维随机行走

若他在三位空间中胡乱的飞, 那么概率密度函数可写为

$$w(x, y, z) = w_x(x)w_y(y)w_z(z) \quad (1.8)$$

特别的, 若 $p = q = \frac{1}{2}$, 则有

$$dP(x, y, z) = w(x, y, z)dxdydz = \left(\frac{\beta}{\pi}\right)^{\frac{3}{2}} e^{-\beta(x^2+y^2+z^2)} dxdydz \quad (1.9)$$

式中 $\beta = \frac{1}{2N}$ 容易在球坐标下求得此积分

$$dP(\vec{r}) = w(x, y, z)dxdydz = \left(\frac{\beta}{\pi}\right)^{\frac{3}{2}} e^{-\beta(r^2)} dr \quad (1.10)$$

此式即是麦克斯韦位置分布率

虽然严格的定义有些繁琐, 但思路异常清晰, 结论非常简洁, 事情仿佛如此般简单。

1.3 更一般的无规行走

不对, 她敏锐的发现事情并未结束。仔细看之前的假设, 在二维的情况下, 我们实际上只考虑了左上, 右上, 左下, 右下四种情况, 因为我们将每次移动分解成了 x, y 方向上的移动, 而且每个方向上步长恒定为 1, 这显然并不随机! 于是她提出了一个看似无理的问题

杂乱无章的走

他醉的真的很厉害, 因而方向是随机的, 步长也是随机的, 但, 我是说有这种可能, 她仍然想知道他的位置 x 的概率分布。

令人惊奇的是, 答案仍然是高斯分布! 只要 N 足够大, 且每步是相互独立而平权的 (即没有哪一步是独特的)。高斯分布是相当普适的, 即是在如此质朴的假设下。我们将会看到, 证明是稍有技巧的, 但令人愉快的是, 我们关心的, 正如所有的高斯分布一样, 只有均值和方差。

幸运的是, 我们仍然只需要讨论一维情形, 因为之前多维之讨论依然适用! 而且思路仍然清晰——现在步长为随机量, 我们可以从其概率密度入手, 不难得出以下结论。

定理 1.6

现在每一步 $s_i, i = 1, 2 \dots N$ 为连续型随机数, 由于每一步是平权的, 它们拥有相同的概率密度 $w(s)$, 相同的平均数 \bar{s} , 以及方差 $(\Delta s)^2$, 由 $x = \sum_{i=1}^N s_i$ 易得

1. $\bar{x} = N\bar{s}, \quad \Delta x = \sum_{i=1}^N \Delta s_i$
2. $(\Delta x)^2 = \sum_{k=1}^N (\Delta s_i)^2 + \sum_{i \neq j}^N (\Delta s_i)(\Delta s_j) = N(\Delta s)^2$



其中 $\sum_{i \neq j}^N (\Delta s_i)(\Delta s_j) = 0$, 由 s_i, s_j 统计独立不难推出。

我们可以轻松的写出概率密度函数

普适的无规行走

每一步 $s_i, i = 1, 2 \dots N$ 为连续型随机数, 拥有相同的概率密度 $w(s)$, 当 N 相当大时, 概率密度函数 $w(x)$ 可以写作

$$w(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (1.11)$$

式中 $\mu = N\bar{s}, \quad \sigma = N(\Delta s)^2$

但我们仍对此存疑, 一是我们用的是离散求和获得的均值与方差, 二是我们到目前位置还没说明为什么是高斯分布! 证明是精巧的。

证明 给出概率是相当容易的, 我们仅需把每一步对应的概率相乘。

$$p(x) = \int \left(\prod_{i=1}^N w(s_i) ds_i \right) \quad (1.12)$$

但困难之处在于 s_i 间有制约关系将积分区域限制在 $\sum_{i=1}^N s_i = x$ 。但是我们可以用 δ 函数来处理。

$$p(x) = \int_{-\infty}^{+\infty} \delta(x - \sum_{i=1}^N s_i) \left(\prod_{i=1}^N w(s_i) ds_i \right) \quad (1.13)$$

将 δ 函数傅里叶展开, 带入得

$$p(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \left(\prod_{i=1}^N w(s_i) ds_i \right) \int_{-\infty}^{+\infty} e^{ik(\sum_{i=1}^N s_i - x)} dk \quad (1.14)$$

$$p(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} Q^N(k) e^{-ikx} dk \quad (1.15)$$

式中 $Q(k) = \int_{-\infty}^{+\infty} w(s_i) e^{iks_i} ds_i$, 对其中 e^{-iks_i} 进行泰勒展开, 并取到二阶项

$$Q(k) = 1ik\bar{s}_i - \frac{1}{2}k^2s_i^2 \quad (1.16)$$

$$\ln(Q^N(k)) = N \ln(1 - ik\bar{s}_i - \frac{1}{2}k^2s_i^2) = N(ik\bar{s}_i - \frac{1}{2}k^2s_i^2 + \frac{1}{2}k^2(\bar{s}_i)^2) = N(ik\bar{s} - \frac{1}{2}k^2(\Delta s)^2) \quad (1.17)$$

带回 $p(x)$ 积分化为了高斯积分

$$p(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{N(ik\bar{s} - \frac{1}{2}k^2(\Delta s)^2) - ikx} dk \quad (1.18)$$

完成积分, 即可证明。

quod erat demonstrandum

事实上, 这就是赫赫有名的林德伯格中心极限定理

1.4 无法做到准连续近似的情况

把注意力放在概率极小的事件上是毫无意义的，毕竟我们已经解决了几乎 99% 的情况，但真是这样吗？她可能会反驳说任何小概率事件都必然发生。抛开这句话本身，小概率的二项分布也颇负盛名，即泊松分布

泊松分布

对于二项分布 $p(n) = \frac{N!}{n!(N-n)!} p^n q^{N-n}$ ，若 $p \ll 1, n \ll N$ ，那么我们可以作如下近似

1. $(N-n)\ln(1-p) \approx -Np$ ，即是 $(1-p)^{N-n} \approx e^{-Np}$

2. $\frac{N!}{(N-n)!} \approx N^n$

那么易得 $p(n) = \frac{\lambda^n}{n!} e^{-\lambda}$ ，即为泊松分布

容易证明（利用 e 指数的泰勒展开）泊松分布具有下述性质

1. 归一性 $\sum_{n=0}^{\infty} p(n) = 1$

2. $\bar{n} = \lambda$

3. $\overline{(\Delta n)^2} = \lambda$